

Assignment 4: Knowledge Graph RAG Agent Report

CE8014 AI 代理系統之設計與開發

2026-04-19

Section 1: Error Layer Diagnostics

本作業實作基於 Neo4j 的 Knowledge Graph (KG) RAG 系統，用以回答校園法規問題。系統使用 Qwen2.5-3B-Instruct 作為本地 LLM，經過三次迭代優化後，最終準確率達到 **80% (16/20)**。

RAG 系統的準確率受到三個處理階段的影響：

1.1 KG 抽取誤差 (Bucket A)

知識圖譜的建立 (`build_kg.py`) 依賴 LLM 從法規文本抽取結構化 Rule 節點。

誤差來源：

- LLM 需將法規文本轉換為 JSON 格式 (type、action、result 等欄位)
- 結構複雜的法規 (多重條件、數值限制、身分區別) 可能抽取遺漏
- 源頭遺失資訊，後續檢索與生成無法挽回

1.2 檢索誤差 (Bucket B)

本系統使用 Neo4j 的全文檢索 (基於 Lucene)，採用 Lexical Search (字面匹配)。

誤差來源：

- 全文檢索只認字面上的字，不懂語意關聯
- 若問題用詞與 KG Rule 用詞不一致，正確答案排序較低
- 如 “penalty” vs “zero grade” 字面不相關

1.3 LLM 回答誤差 (Bucket C)

檢索結果經 Prompt 組裝後傳給 LLM 生成答案。

誤差來源：

- 若檢索結果包含多條不一致的 Rule (如多條 60 分與一條 70 分)
- LLM 可能受「雜訊干擾效應」影響，選擇出現頻率較高的錯誤答案

Section 2: Iteration History

Stage 1: Baseline 建立

初次運行準確率：**70% (14/20)**

主要問題：

- 關鍵詞過濾過於嚴格（如 ID 因長度 =2 被濾除）
- 同義詞不匹配（如 “invigilator” vs “proctor”）
- 檢索排序不精確

Stage 2: 檢索層優化

改進措施：

1. 關鍵詞白名單：加入 ID、PE 等有意義的短詞
2. 同義詞映射：將不同用詞映射到 KG 標準用詞
3. **Domain Keyword** 注入：根據問題類型補充相關關鍵詞
4. 檢索權重調整：調整 typed_query 與 broad_query 的權重比例

成果：準確率提升至 **75% (15/20)**

Stage 3: 生成層優化

改進措施：

1. **Article Snippet** 輔助：附上原始法規片段作為上下文
2. **Prompt** 工程：指示 LLM 如何處理數值衝突與身分區別
3. **Top-K** 擴充：LLM 可參考的 Rule 數量從 5 提升至 10

成果：準確率提升至 **80% (16/20)**

Top-K 擴充實驗

Top-K	準確率	FAIL 題目
5	16/20 (80%)	Q5, Q17, Q18, Q19
10	16/20 (80%)	Q5, Q17, Q18, Q19

結論：擴大 Top-K 無法解決根本問題。若 KG 缺少 Rule 或檢索排序讓雜訊蓋過正確答案，增加 Context 只會增加雜訊干擾。

Section 3: Final Experiment Trace

```
[*] Starting LLM Evaluation for 20 Questions...

Q1: How many minutes late before barred from exam?
  Bot: A student can be up to 20 minutes late...
  Time: 15.22s
  Result: PASS

Q2: Can I leave the exam room 30 minutes after it starts?
  Bot: No, you cannot leave the exam room...
  Time: 5.39s
  Result: PASS

Q3: What is the penalty for forgetting my student ID?
  Bot: The penalty is having five points deducted...
  Time: 3.40s
  Result: PASS

Q4: What is the penalty for using electronic devices...
  Bot: The penalty is a five-point deduction...
  Time: 3.68s
  Result: PASS

Q5: What is the penalty for cheating, copying or passing notes?
  Bot: The penalty is a five-point deduction...
  Time: 3.87s
  Result: FAIL (expected: zero score + disciplinary)

Q6: Is a student allowed to take the question paper out?
  Bot: According to Rule 9, violators receive zero grade...
  Time: 6.10s
  Result: PASS

Q7: What happens if a student threatens the invigilator?
  Bot: Zero grade + misconduct reported...
  Time: 5.55s
  Result: PASS

Q8: What is the fee for replacing a lost EasyCard student ID?
  Bot: The fee is NTD 200...
  Time: 4.12s
  Result: PASS

Q9: What is the fee for replacing a lost Mifare student ID?
  Bot: The fee is NTD 100...
  Time: 4.54s
```

Result: PASS

Q10: How many working days to get a new student ID?

Bot: 3 working days

Time: 2.90s

Result: PASS

Q11: What is the minimum credits for undergraduate graduation?

Bot: 128 credits

Time: 2.23s

Result: PASS

Q12: How many semesters of PE are required?

Bot: Five semesters

Time: 2.14s

Result: PASS

Q13: Are Military Training credits counted?

Bot: Military Training is not counted...

Time: 2.39s

Result: PASS

Q14: What is the standard duration for a bachelor's degree?

Bot: 4 years

Time: 3.41s

Result: PASS

Q15: What is the maximum extension period?

Bot: Two academic years

Time: 3.16s

Result: PASS

Q16: What is the passing score for undergraduate?

Bot: 60 marks

Time: 3.02s

Result: PASS

Q17: What is the passing score for graduate students?

Bot: 60 marks

Time: 3.72s

Result: FAIL (expected: 70 marks)

Q18: Under what condition will a student be dismissed?

Bot: Insufficient rule evidence

Time: 2.66s

Result: FAIL (expected: failing > half credits)

Q19: Can a student take a make-up exam for failed grade?

Bot: Insufficient rule evidence
Time: 2.98s
Result: FAIL (expected: No)

Q20: What is the maximum leave of absence duration?

Bot: Two academic years
Time: 3.37s
Result: PASS

=====
Summary: 16/20 PASS, 4/20 FAIL
Accuracy: 80.0%
=====

Section 4: Failure Analysis

Q5: 作弊處罰

項目	結果
問題	What is the penalty for cheating?
正確答案	Zero score + disciplinary action
KG 狀態	有 Rule 8 “pass notes…zero grade”
檢索排序	Rule 8 排第 8，Top 5 都是 5-point deduction
Root Cause	Bucket B - Lexical Search 不匹配

Q17: 研究生及格分數

項目	結果
問題	What is the passing score for graduate students?
正確答案	70 points
KG 狀態	有 Article 59 “lowest passing grade is 70 marks”
檢索排序	正確 Rule 在前，但多條 60 marks Rule 干擾
Root Cause	Bucket C - 雜訊干擾效應

Q18: 退學條件

項目	結果
問題	Under what condition will a student be dismissed?
正確答案	Failing > half credits for 2 semesters
KG 狀態	有 Article 21 包含完整退學條件
檢索排序	排序不佳，關鍵詞被稀釋
Root Cause	Bucket B - 檢索排序問題

Q19: 補考規定

項目	結果
問題	Can a student take a make-up exam?
正確答案	No
KG 狀態	有 Article 20 “should not receive make-up exams”
檢索排序	PE Rule 排名較高，正確 Rule 排名較低
Root Cause	Bucket B - 檢索排序問題

Root Cause 總結

題目	Root Cause	層級
Q5	關鍵詞不匹配	Bucket B
Q17	雜訊干擾效應	Bucket C
Q18	檢索排序不佳	Bucket B
Q19	檢索排序不佳	Bucket B

Bucket A = KG 抽取誤差、Bucket B = 檢索誤差、Bucket C = LLM 回答誤差

重要發現：所有失敗題目的 KG 都包含正確答案，問題主要在檢索層與生成層。

Section 5: Reflection

5.1 Lexical Search 的限制

本系統使用 Lucene 全文檢索，存在先天限制：

- 字面匹配：只認字面上的字，不懂語意關聯
- 同義詞問題：“penalty” 與 “zero grade” 字面不相關
- 排序稀釋：重要關鍵詞若在多條 Rule 出現，權重被稀釋

5.2 改進方向

短期

- 同義詞表擴充
- 檢索權重調整
- Prompt 工程優化

長期（需要重建 KG）

- Rule 標籤優化（加入身分標籤）
- 引入 Semantic Search（Embedding 向量檢索）

5.3 Key Findings

1. 檢索層是 **RAG** 系統的天花板：即使 KG 包含完整資訊，若 Lexical Search 無法精準匹配，LLM 也無法正確回答。
2. **Top-K** 擴充不是萬靈丹：擴大 Context Window 只會增加雜訊，無法解決檢索排序的根本問題。
3. **Lexical Search** 的先天限制：字面匹配不懂語意，需透過同義詞映射或向量檢索補足。
4. 三層誤差需分層診斷：在改進系統前，需先確認是 Bucket A/B/C 哪一層的問題，避免改錯方向。